

Moteur de recherche sémantique et analytique sur des logs massifs Big Data

Contexte

Les systèmes Big Data (réseaux, cloud, plateformes industrielles, e-services) génèrent des volumes massifs de logs textuels.

Ces logs sont difficiles à exploiter par des méthodes classiques (recherche par mots-clés).

L'objectif du projet est de construire une plateforme Big Data capable de :

- ingérer un grand volume de logs
- transformer les messages en vecteurs
- stocker ces vecteurs dans une base vectorielle
- effectuer des recherches sémantiques et analytiques

Objectifs pédagogiques

- Manipuler des données massives
- Comprendre l'architecture Big Data (batch / pipeline)
- Appliquer la recherche sémantique à grande échelle
- Intégrer des bases de données vectorielles dans un flux Big Data
- Analyser des logs pour détection de motifs récurrents

Technologies imposées (Open Source)

- Python
- Apache Spark
- PostgreSQL + pgvector
- Sentence-Transformers

Jeu de données (public – Big Data)

Jeux de logs massifs disponibles publiquement :

- Logs systèmes Linux (HDFS, Hadoop)
- Logs Apache / Web server
- Logs de services cloud (Kaggle)
- Dataset LogHub (plusieurs millions de lignes)

Volume recommandé : $\geq 500\,000$ entrées textuelles

Architecture attendue

Dataset de logs



Prétraitement Spark



Génération d'embeddings (batch)



Base vectorielle (pgvector)



Recherche sémantique + analyse

Travail demandé

Phase 1 – Conception Big Data

- Étude du dataset
- Analyse du volume et du format
- Conception du pipeline Big Data
- Schéma de stockage

Phase 2 – Ingestion et traitement massif

- Chargement des logs avec Apache Spark
- Nettoyage et normalisation
- Partitionnement des données

Phase 3 – Vectorisation et indexation

- Génération des embeddings par lots
- Insertion dans la base vectorielle
- Création d'index de similarité

Phase 4 – Recherche et analyse

- Recherche sémantique dans les logs
- Détection de messages similaires
- Analyse des erreurs récurrentes

- Comparaison avec recherche par mots-clés

Cas pratiques imposés

- « Retrouver tous les logs similaires à une erreur critique donnée »
- « Identifier les groupes d’erreurs fréquentes »
- « Analyser l’évolution temporelle des erreurs similaires »

Livrables finaux

1. Code source documenté
2. Pipeline Big Data fonctionnel
3. Base vectorielle indexée
4. Rapport technique (10–15 pages)
5. Démonstration (script ou interface)